Rで学ぶ 傾向スコア解析入門

@yokkuns: 里 洋平

2011.09.24 第17回R勉強会@東京(#TokyoR)

AGENDA

- 自己紹介
- 傾向スコア解析
 - 実験出来るデータ
 - ・実験出来ないデータ
 - 共変量調整
 - 傾向スコア推定
 - 傾向スコアを用いた調整
- Rによる実行
- 最後に

AGENDA

- 自己紹介
- 傾向スコア解析
 - ・実験出来るデータ
 - ・実験出来ないデータ
 - 共変量調整
 - 傾向スコア推定
 - 傾向スコアを用いた調整
- Rによる実行
- 最後に

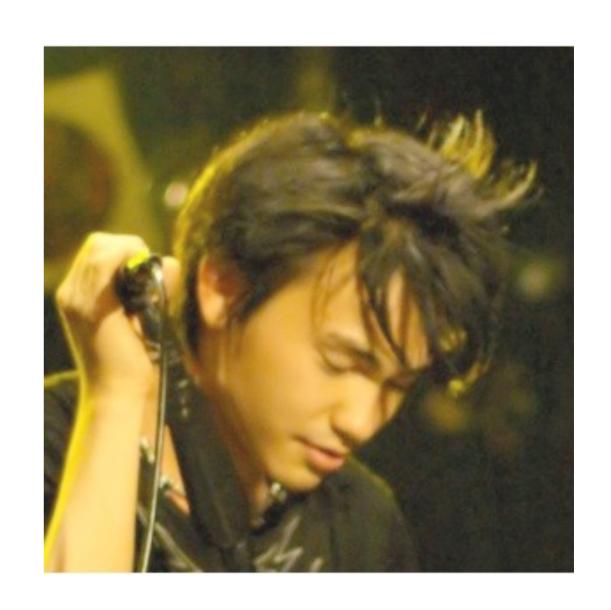
自己紹介

• ID: yokkuns

• 名前:里洋平

データマイニングエンジニア

統計解析 パターン認識 機械学習 データマイニング NLP 金融工学 などを勉強中



Tokyo.Rの主催者





ホーム

ご参加ありがとうございます!

Rパッケージ本執筆





Rパッケージガイドブック [単行本]

図田 昌史 ▼ (著), 荒木 孝治 (その他), 伊藤 康広 (その他), 里 洋平 (その他), 高柳 慎一 (その他), 棚瀬 貴紀 (その他), 谷村 晋 (その他), 中谷 朋昭 (その他), 蓮見 亮 (その他), 林 真広 (その他), 樋口 千洋 (その他), 福島 真太朗 (その他), 独山 文彦 (その他), 横山 貴央 (その他), akira (その他), mickey24 (その他) この商品の最初のレビューを書き込んでください。

価格: ¥ 3,990 通常配送無料 詳細

通常2~4週間以内に発送します。 <u>在庫状況</u>について この商品は、<u>Amazon.co.jp</u> が販売、発送します。 ギフトラッピングを利 用できます。

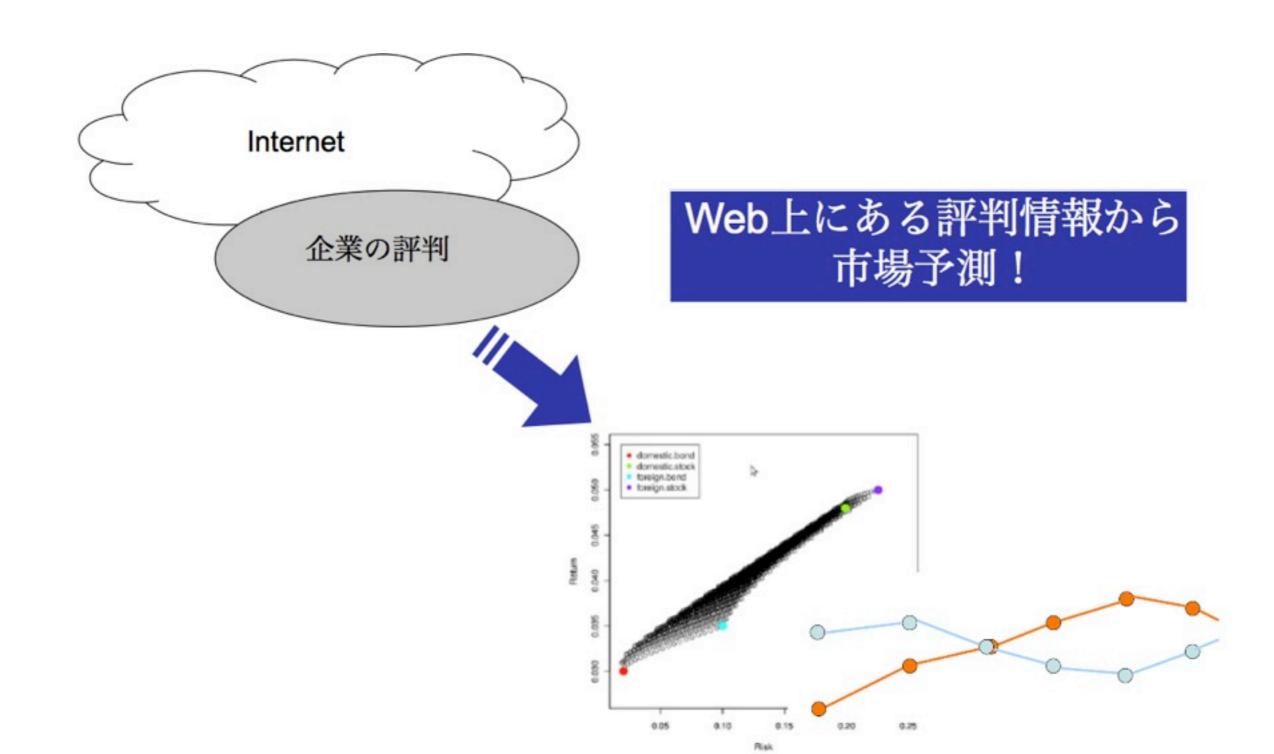
中古品1点¥ 6,133より

動画レコメンド



閲覧されてる動画に関連する おすすめ動画を表示

テキストマイニング+金融工学



AGENDA

- 自己紹介
- 傾向スコア解析
 - 実験出来るデータ
 - ・実験出来ないデータ
 - 共変量調整
 - 傾向スコア推定
 - 傾向スコアを用いた調整
- Rによる実行
- 最後に

実験出来ないデータの因果関係を解析する

3歳神話:子供は3歳までは母親の元で育つ方が社会性・知能発達が向上する

1~3歳まで母親の側



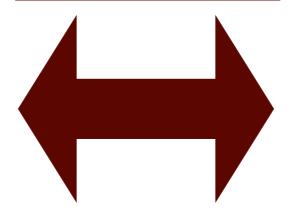
実験出来ないデータの因果関係を解析する

3歳神話:子供は3歳までは母親の元で育つ方が社会性・知能発達が向上する

1~3歳まで母親の側

◇親の学歴

8歳時点の 社会性得点・知能検査 を比較



1~3歳に保育園

◇親の学歴

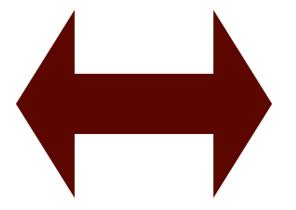
実験出来ないデータの因果関係を解析する

3歳神話:子供は3歳までは母親の元で育つ方が社会性・知能発達が向上する

1~3歳まで母親の側

- ◇親の学歴
- ◇親の収入

8歳時点の 社会性得点・知能検査 を比較



- ◇親の学歴
- ◇親の収入

実験出来ないデータの因果関係を解析する

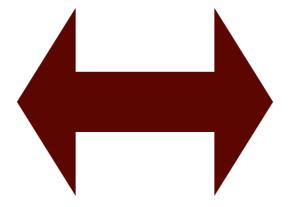
3歳神話:子供は3歳までは母親の元で育つ方が社会性・知能発達が向上する

1~3歳まで母親の側

- ◇親の学歴
- ◇親の収入
- ◇親の職業

8歳時点の

社会性得点·知能検査 を比較



- ◇親の学歴
- ◇親の収入
- ◇親の職業

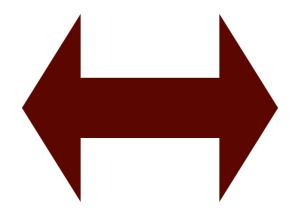
実験出来ないデータの因果関係を解析する

3歳神話:子供は3歳までは母親の元で育つ方が社会性・知能発達が向上する

1~3歳まで母親の側

- ◇親の学歴
- ◇親の収入
- ◇親の職業
- ◇親の教育意欲

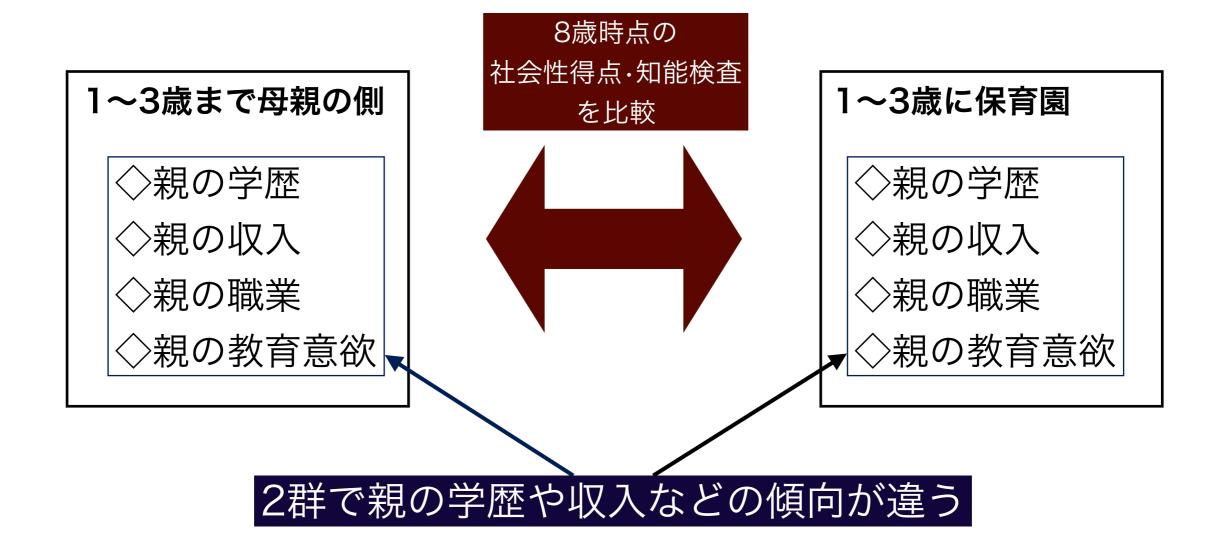
8歳時点の 社会性得点・知能検査 を比較



- ◇親の学歴
- ◇親の収入
- ◇親の職業
- ◇親の教育意欲

実験出来ないデータの因果関係を解析する

3歳神話:子供は3歳までは母親の元で育つ方が社会性・知能発達が向上する

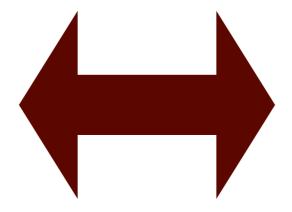


実験出来ないデータの因果関係を解析する

テレビCMの効果測定

TVCMを見たグループ

当該商品の 購買量の比較



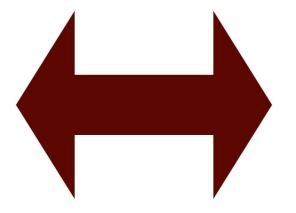
実験出来ないデータの因果関係を解析する

テレビCMの効果測定

TVCMを見たグループ

◇購買意欲

当該商品の 購買量の比較



TVCMを見てないグループ

◇購買意欲

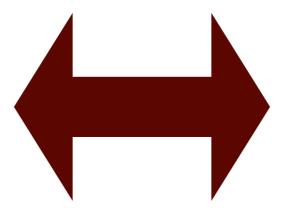
実験出来ないデータの因果関係を解析する

テレビCMの効果測定

TVCMを見たグループ

- ◇購買意欲
- ◇ライフスタイル

当該商品の 購買量の比較



- ◇購買意欲
- ◇ライフスタイル

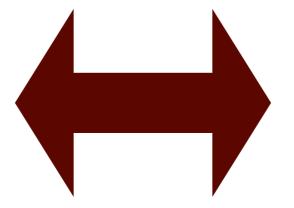
実験出来ないデータの因果関係を解析する

テレビCMの効果測定

TVCMを見たグループ

- ◇購買意欲
- ◇ライフスタイル
- ◇年齢層

当該商品の 購買量の比較



- ◇購買意欲
- ◇ライフスタイル
- ◇年齢層

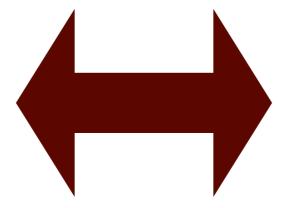
実験出来ないデータの因果関係を解析する

テレビCMの効果測定

TVCMを見たグループ

- ◇購買意欲
- ◇ライフスタイル
- ◇年齢層
- ◇所得

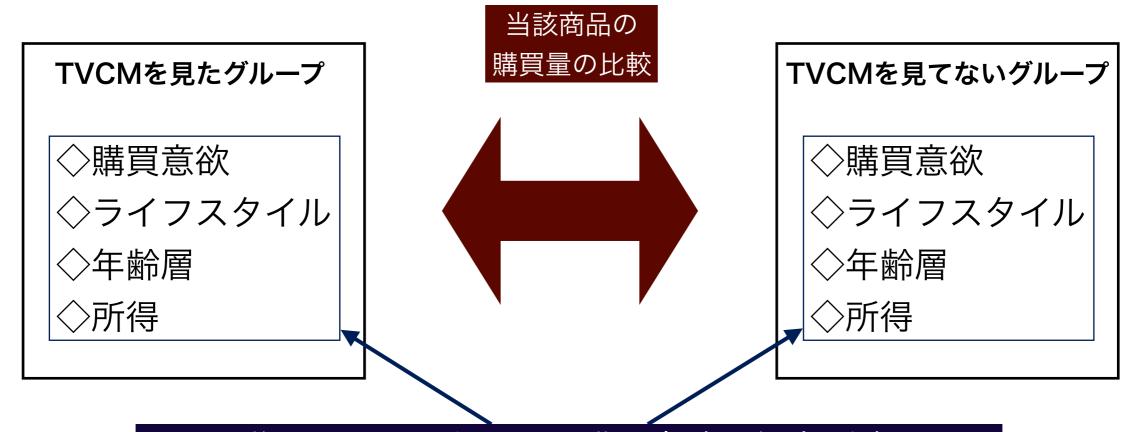
当該商品の 購買量の比較



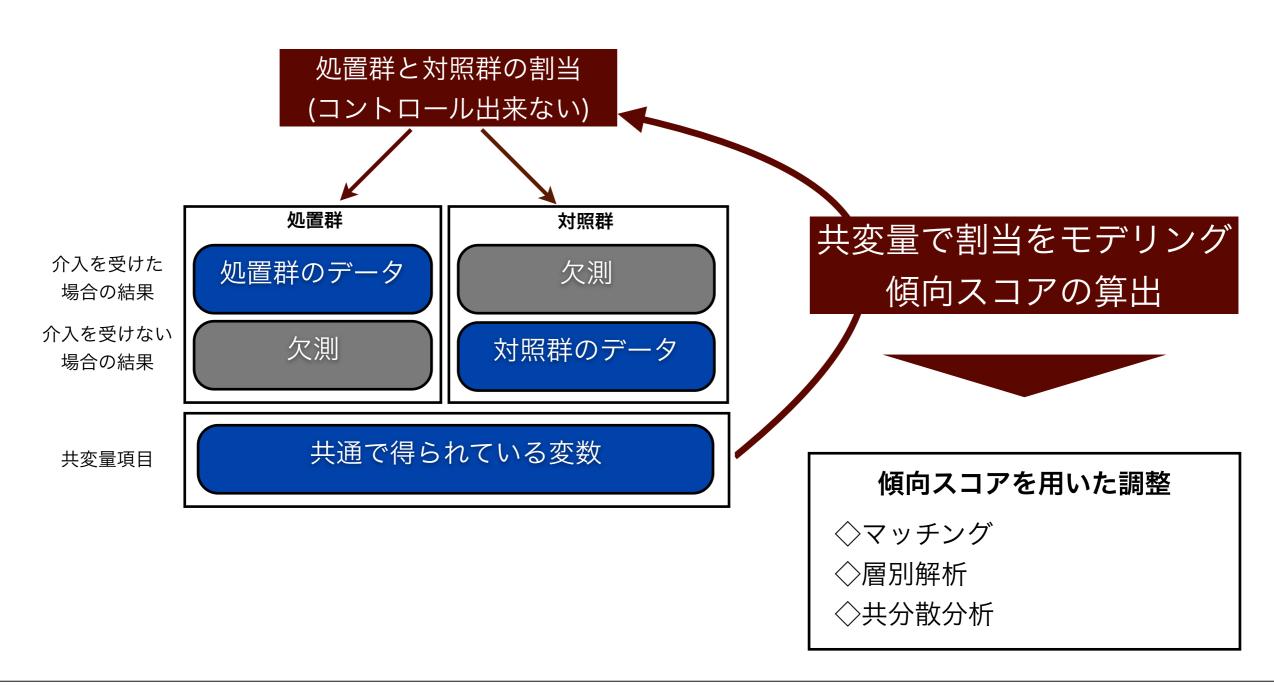
- ◇購買意欲
- ◇ライフスタイル
- ◇年齢層
- ◇所得

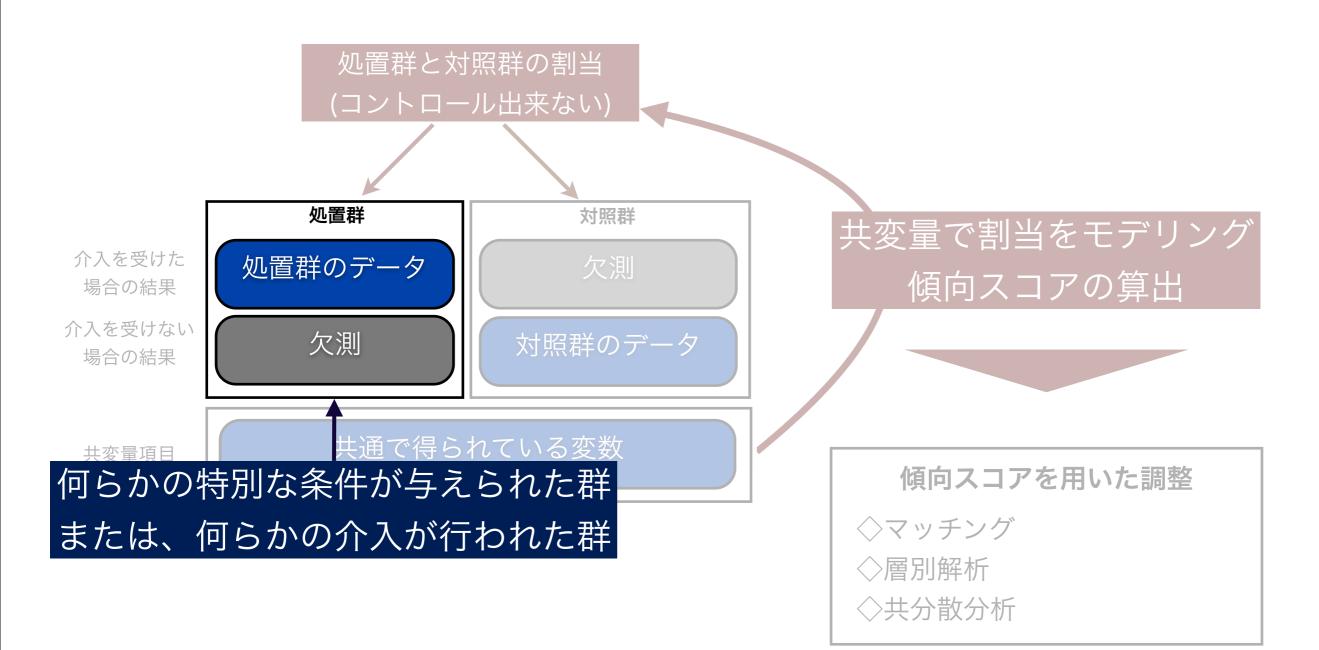
実験出来ないデータの因果関係を解析する

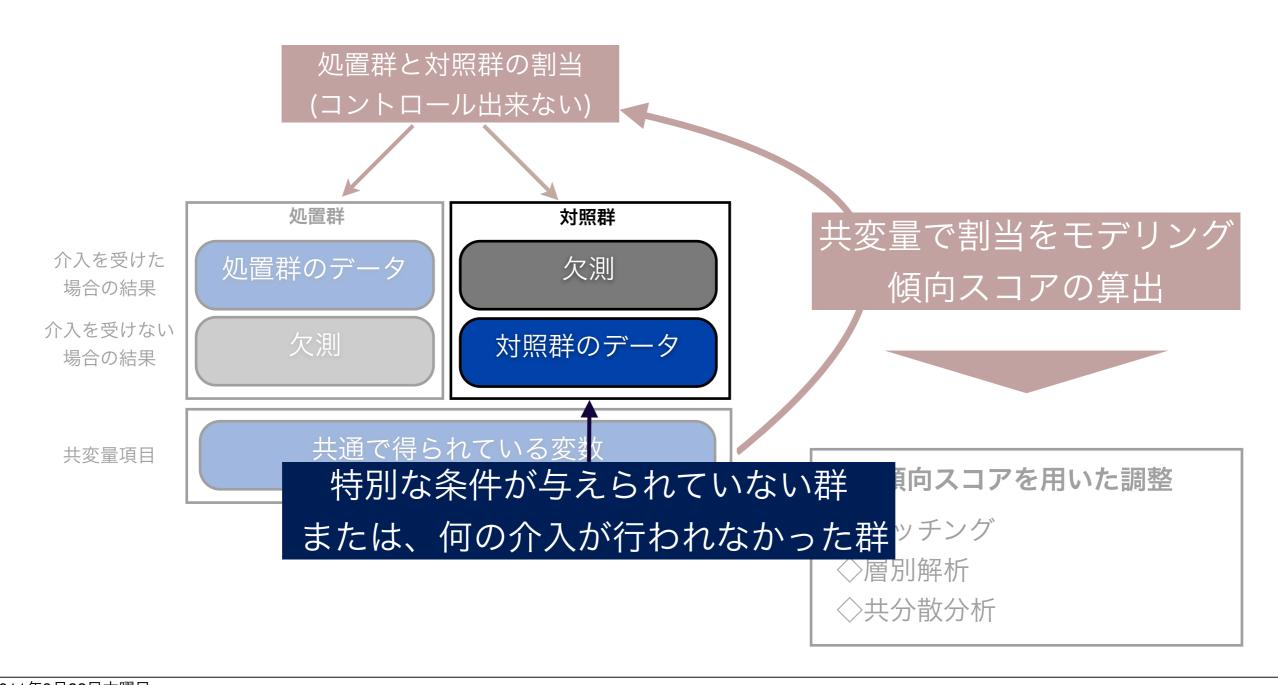
テレビCMの効果測定



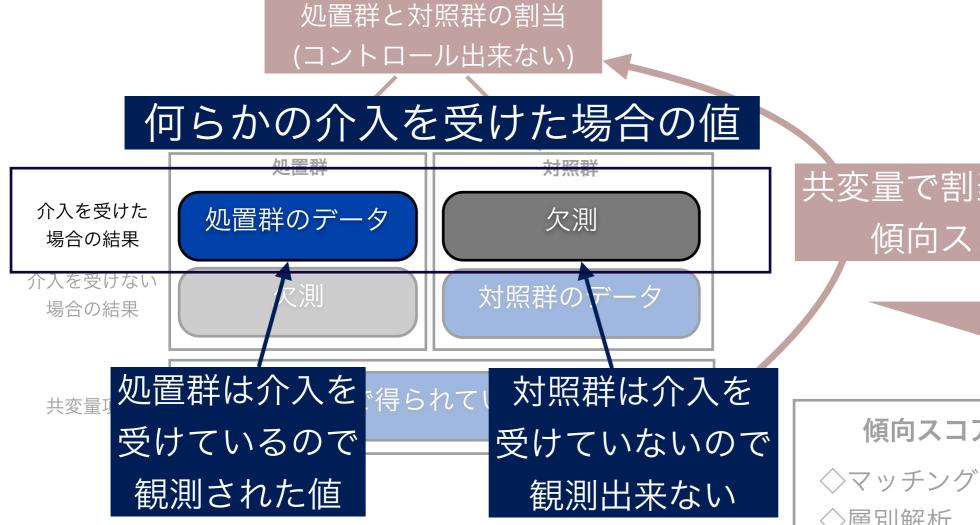
2群でライフスタイルや購買意欲の傾向が違う 企業ターゲット層に合わせた時間にCMを出稿している







実験出来ないデータの因果関係を解析する

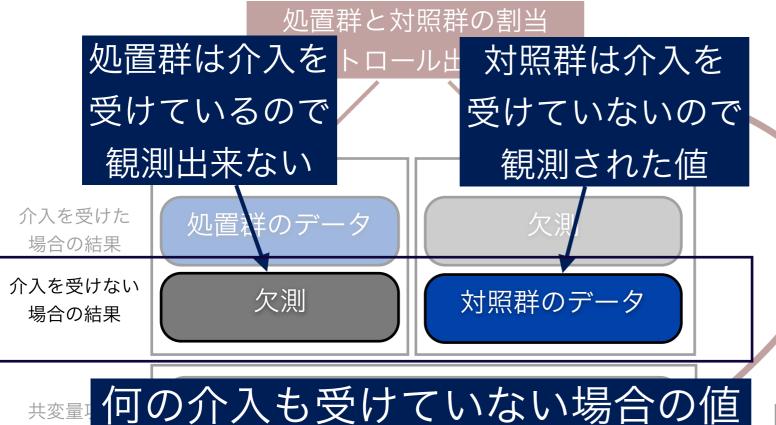


共変量で割当をモデリング 傾向スコアの算出

傾向スコアを用いた調整

- ◇層別解析
- ◇共分散分析

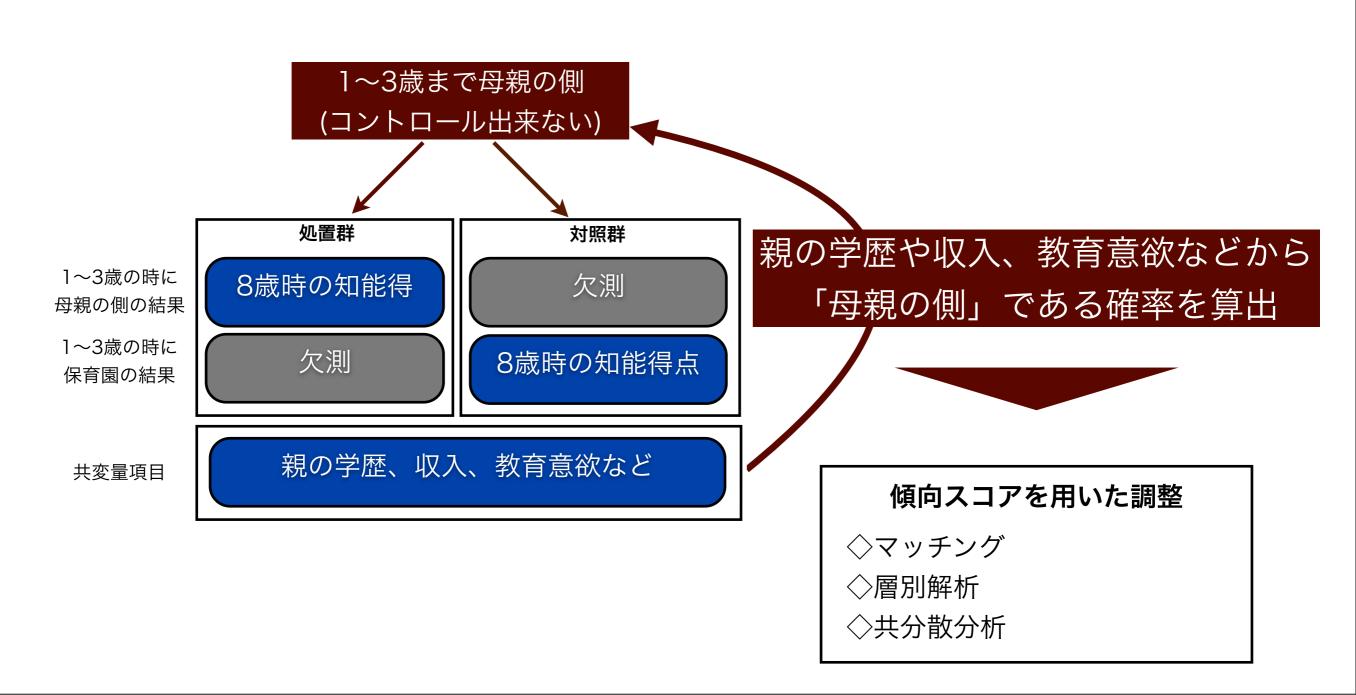
実験出来ないデータの因果関係を解析する

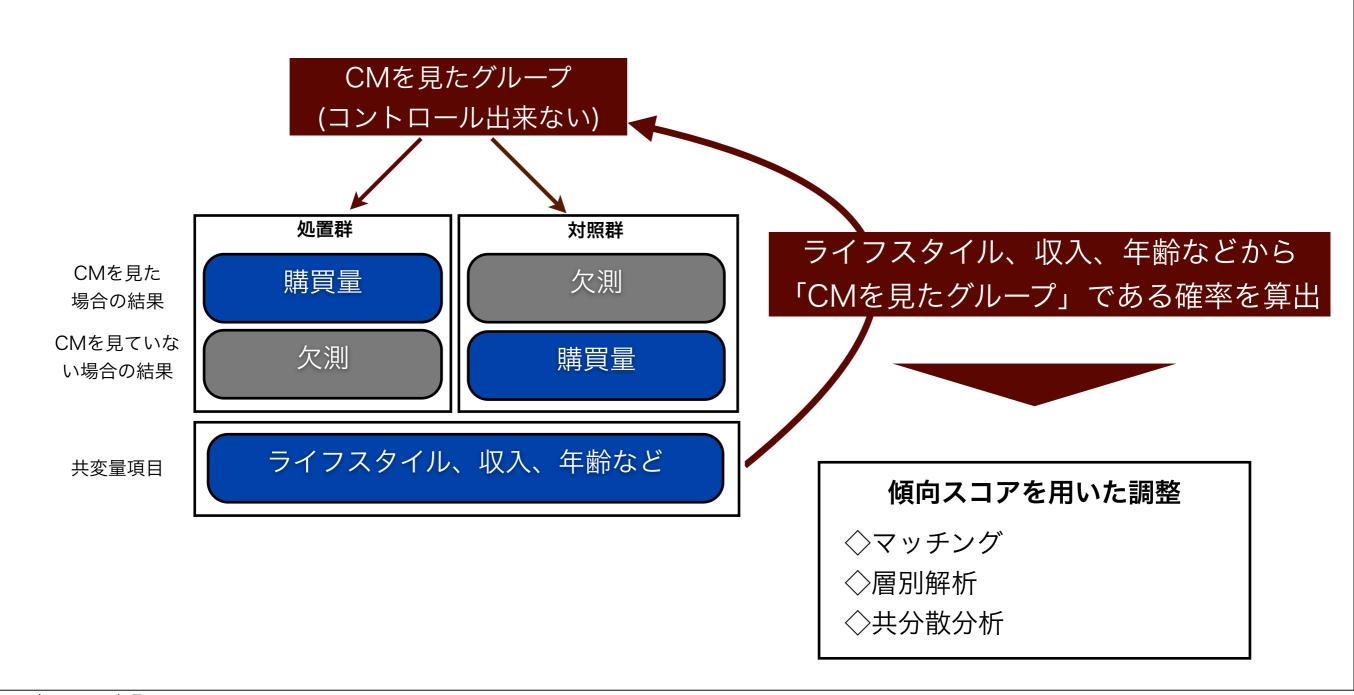


共変量で割当をモデリング 傾向スコアの算出

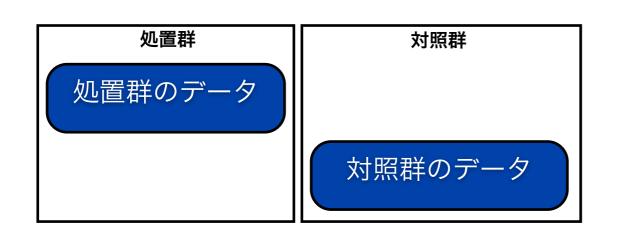
傾向スコアを用いた調整

- ◇マッチング
- ◇層別解析
- ◇共分散分析

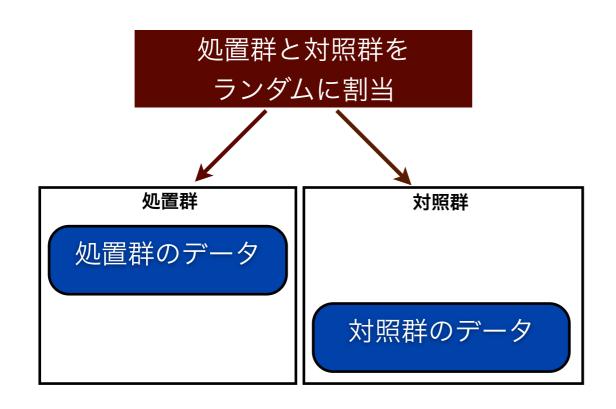




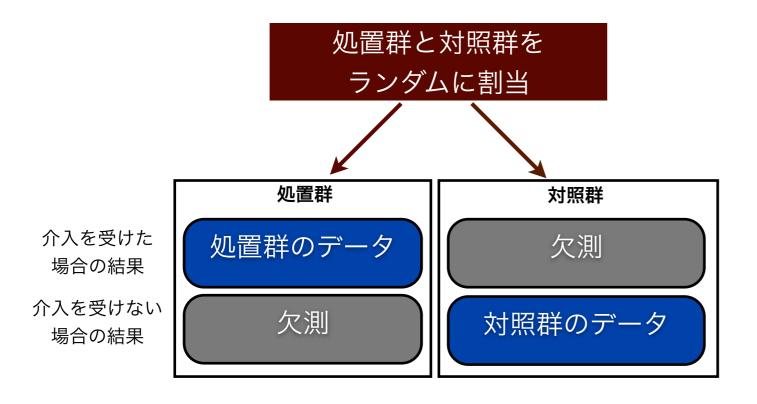
因果効果は単純な処置群と対照群の差になる



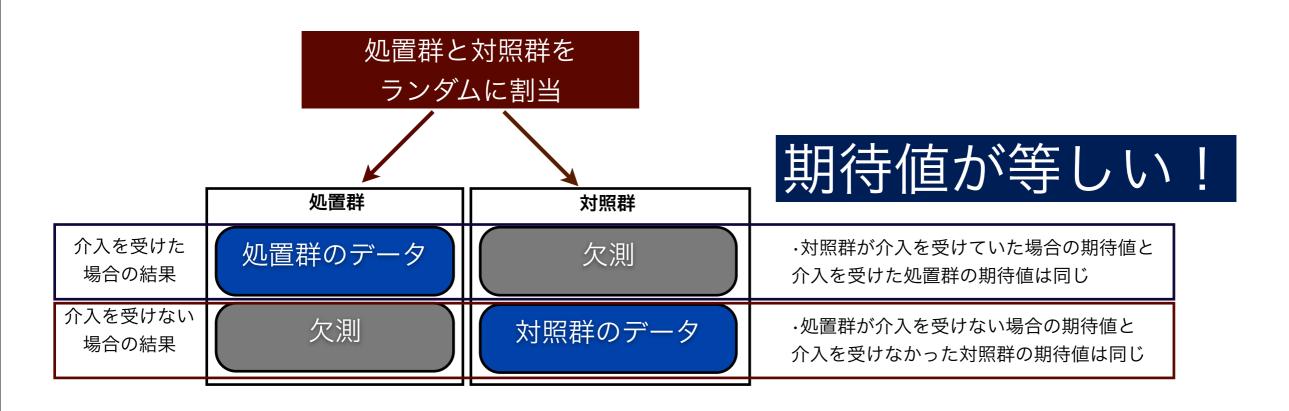
因果効果は単純な処置群と対照群の差になる



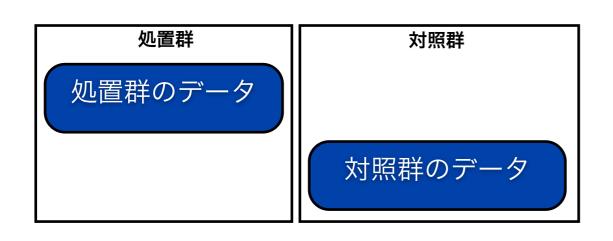
因果効果は単純な処置群と対照群の差になる



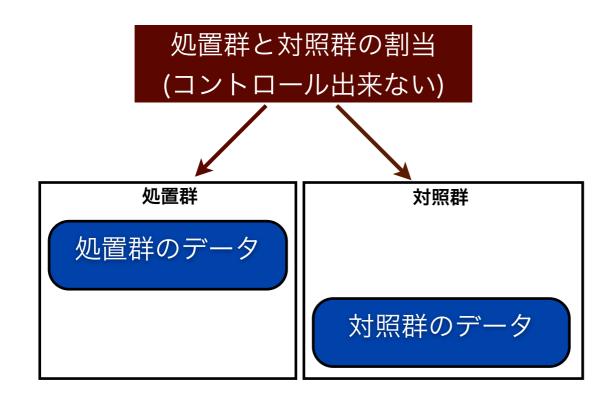
因果効果は単純な処置群と対照群の差になる



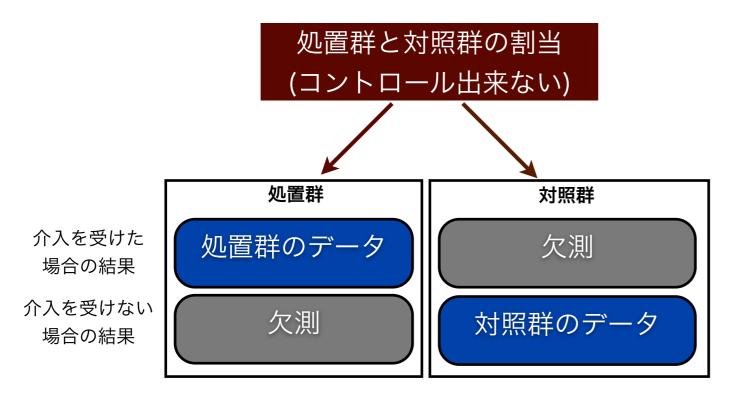
割当によって処置群と対照群に差が生じるため 単純に比較することが出来ない



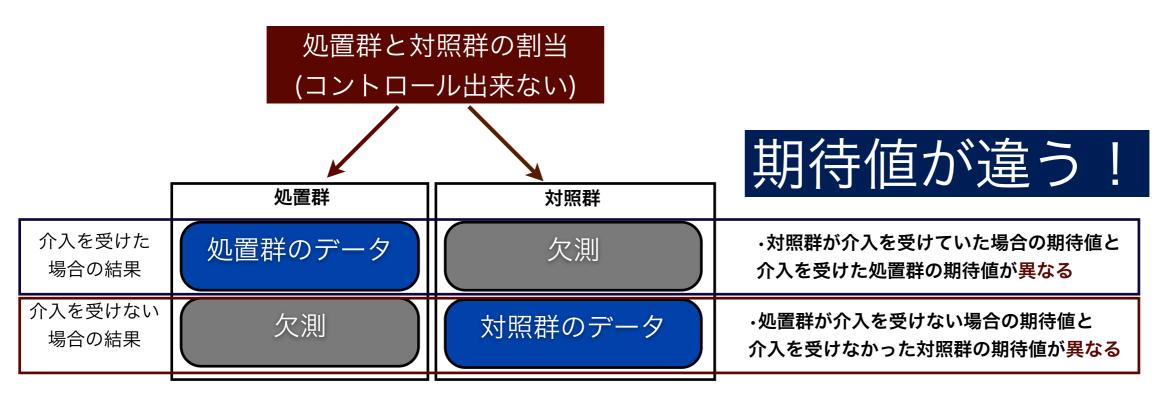
割当によって処置群と対照群に差が生じるため 単純に比較することが出来ない



割当によって処置群と対照群に差が生じるため 単純に比較することが出来ない



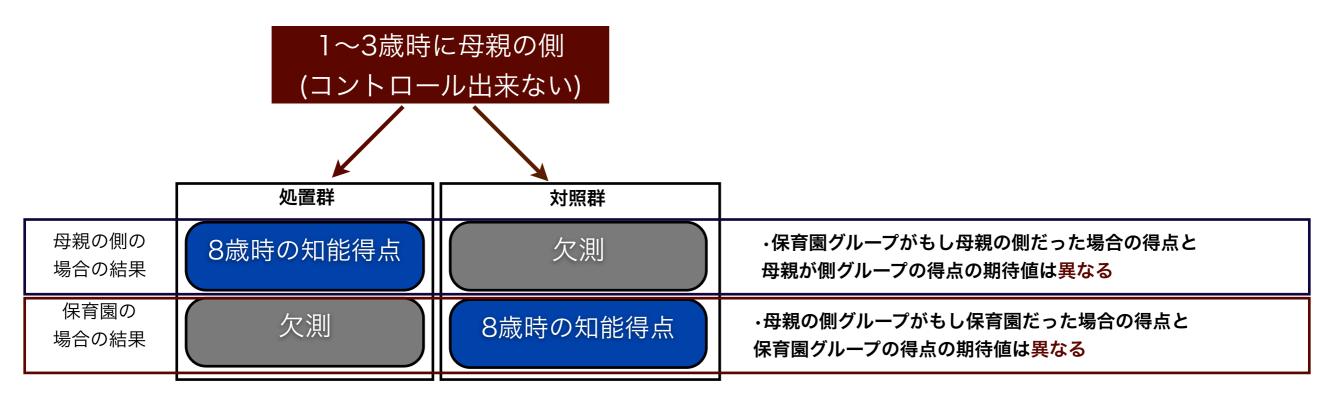
割当によって処置群と対照群に差が生じるため 単純に比較することが出来ない



実験出来ないデータ

3歳神話:母親側グループと保育園グループを

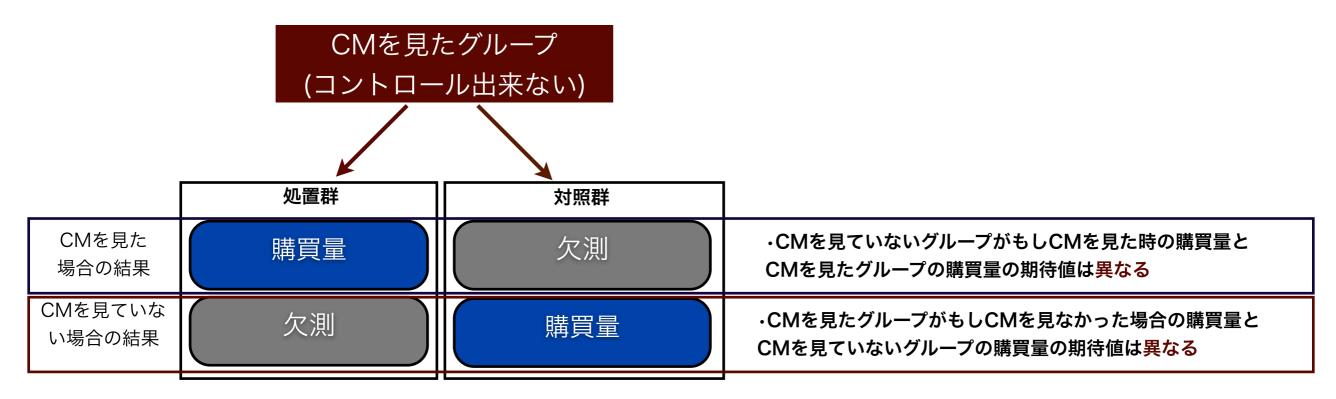
単純に比較することは出来ない



母親側効果 ≠ "母親側" - "保育園"

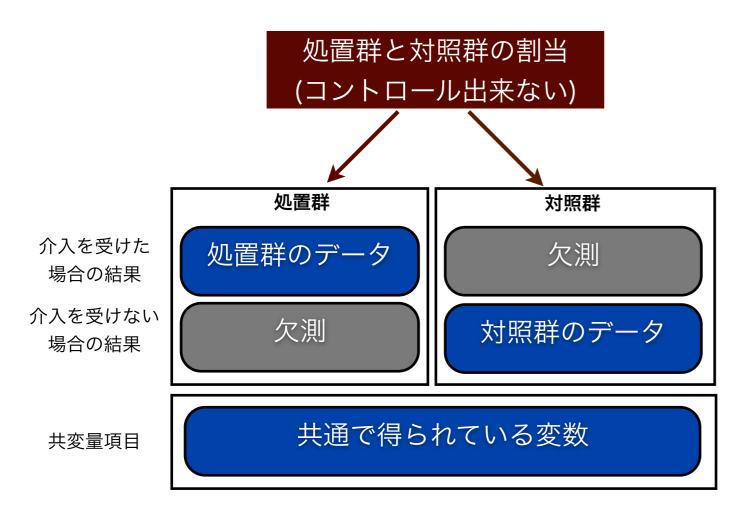
実験出来ないデータ

CM効果: CM見たグループと見てないグループを 単純に比較することは出来ない

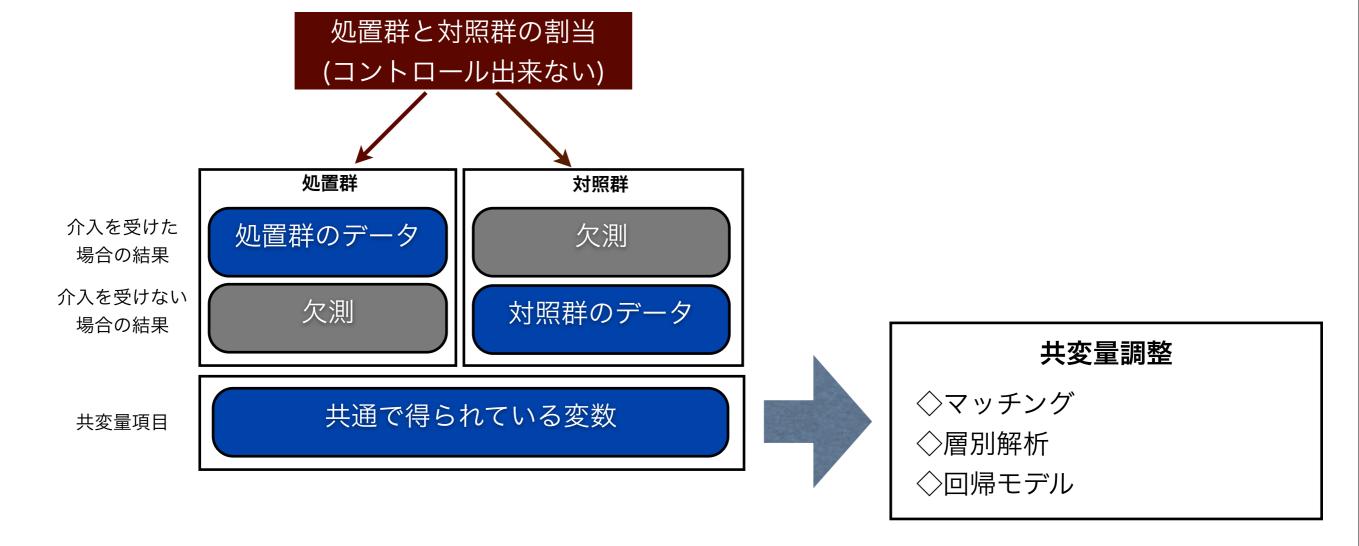


CM効果 # "CM見た" - "CM見てない"

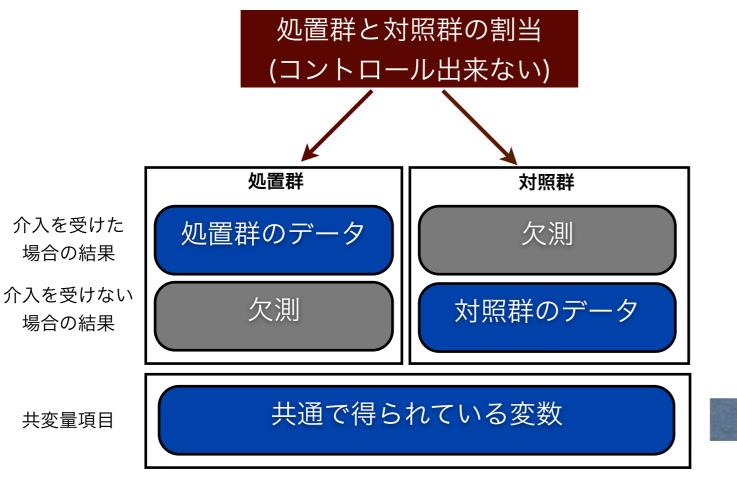
割当や結果変数に影響している共通の変数を用いて 因果効果以外の効果を除去する



割当や結果変数に影響している共通の変数を用いて 因果効果以外の効果を除去する



割当や結果変数に影響している共通の変数を用いて 因果効果以外の効果を除去する



親の学歴、収入、教育意欲など 共通で得られる性質を揃えて 2群を比較する



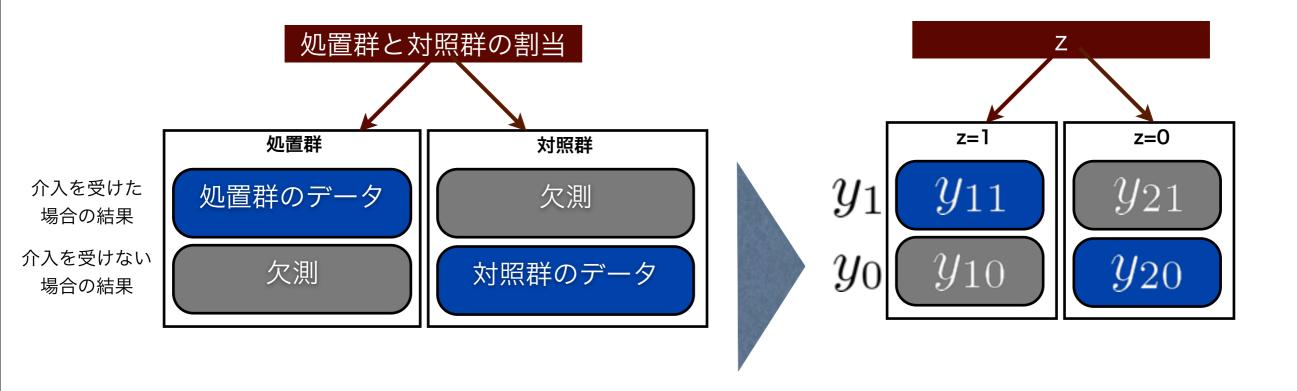
共変量調整

- ◇マッチング
- ◇層別解析
- ◇回帰モデル

潜在的結果変数を考える

割当によって観測出来ないと考える

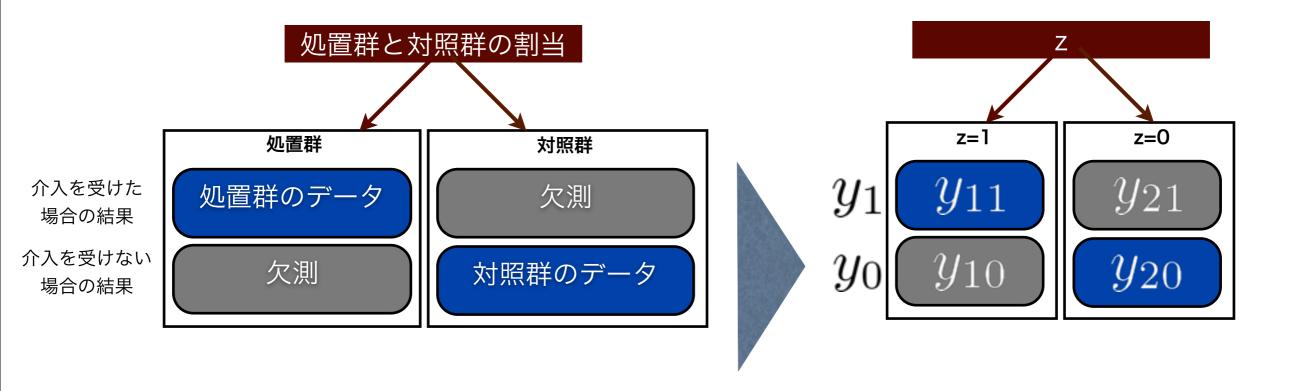
割当変数zと求めたい因果効果



$$TET = E(y_1 - y_0|z = 1)$$

処置群での平均介入効果 average treatment effect on the treated

割当変数zと求めたい因果効果

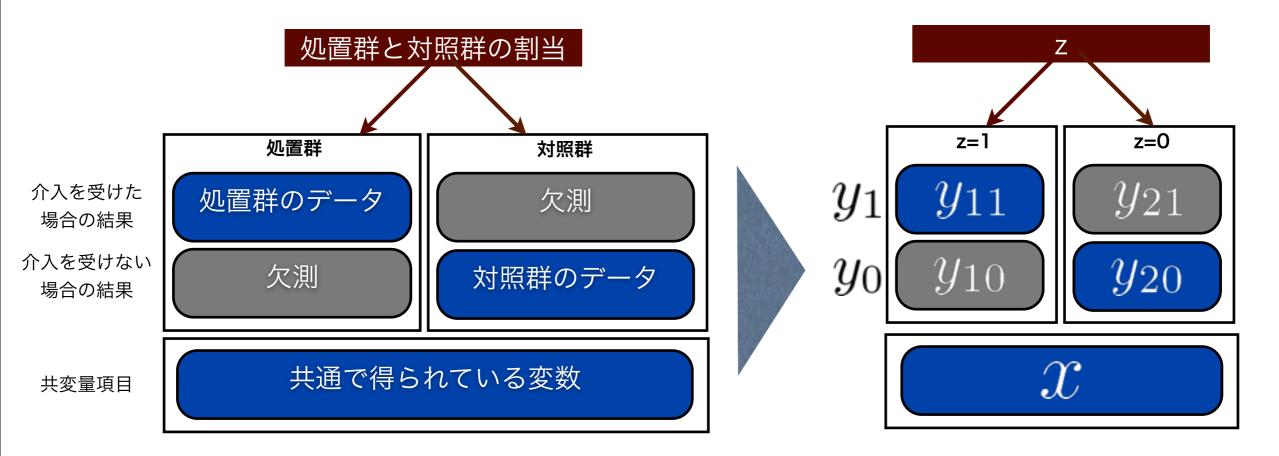


$$TET = E(y_1 - y_0|z = 1)$$

処置群での平均介入効果 average treatment effect on the treated

z=1の時のy1とy0の差を知りたいが どちらか一方は観測出来ない

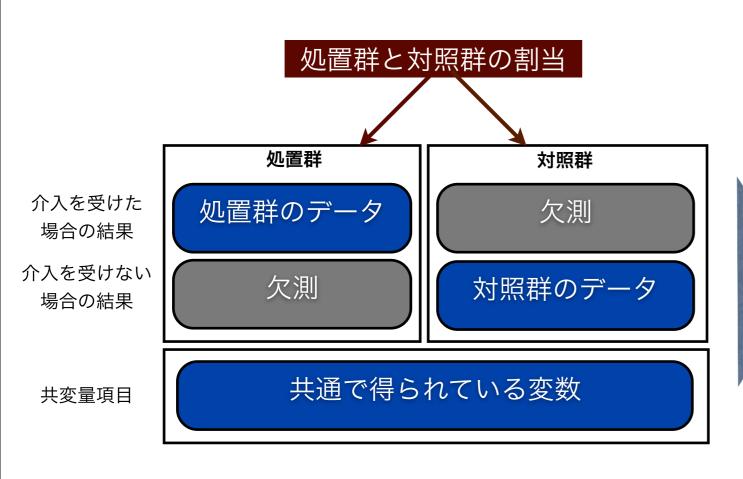
共変量の影響を除去した因果効果

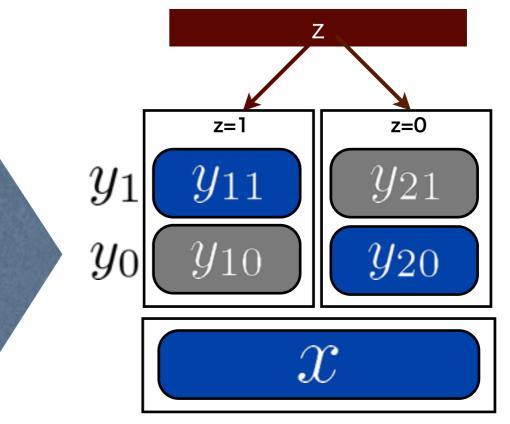


強く無視出来る (y_1,y_0) $\perp\!\!\!\!\perp z|x$ 同じ共変量の時は 割当条件 y_1,y_0 $\perp\!\!\!\!\perp z|x$

共変量の影響を 除去した因果効果: $E(y_1-y_0|\boldsymbol{x})=E(y_1|z=1,\boldsymbol{x})-E(y_0|z=0,\boldsymbol{x})$

共変量の影響を除去した因果効果





強く無視出来る。 (y_1,y_0) 上 $z|m{x}$

共変量の影響を 除去した因果効果: $E(y_1-y_0|m{x})=\!\!\left|E(y_1|z=1,m{x})-E(y_0|z=0,m{x})\right|$

同じ共変量の時はならz=1のy0の期待値を

z=0の時のy0の期待値で代用出来る

・マッチング

処置群と対照群で共変量が同じになる対象者のペアを作り差をとり、ペア数分の平均を取る

• 層別解析

共変量の値をいくつかの層に分け、層ごとで2つのグループがその共変量の値について等質になるようにし、比較した結果を結合する

• 回帰モデル

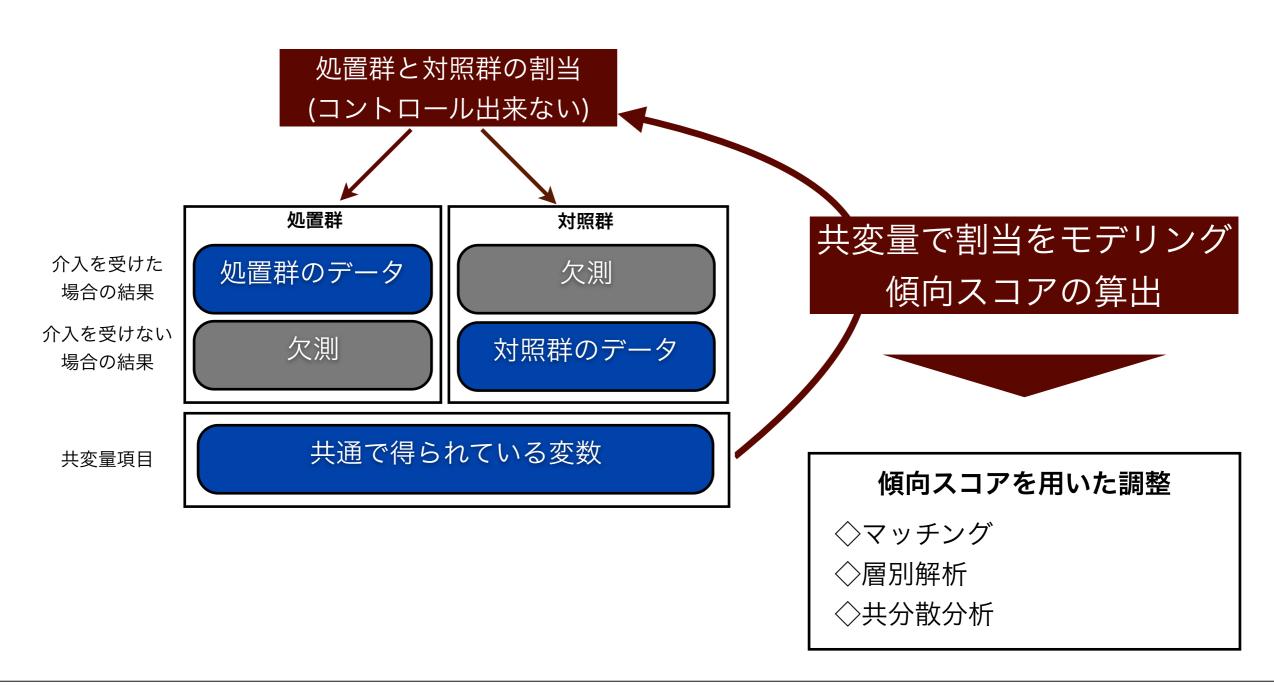
 各群ごとに回帰関数E(y1|z=1,x)とE(y0|z=0,x)を データから推定し、その差の標本平均を取る事で因 果効果を推定する

共変量調整の問題点

- マッチング・層別解析での問題
 - 共変量に連続変数があると完全一致のペア は作れない
 - 次元問題
 - サポート問題
- 回帰モデルでの問題点
 - 結果変数と共変量のモデリングが必要
 - 直接因果効果の推定値は得られない

傾向スコア解析

実験出来ないデータの因果関係を解析する



傾向スコアとは

対象者の群1へ割り当てられる確率

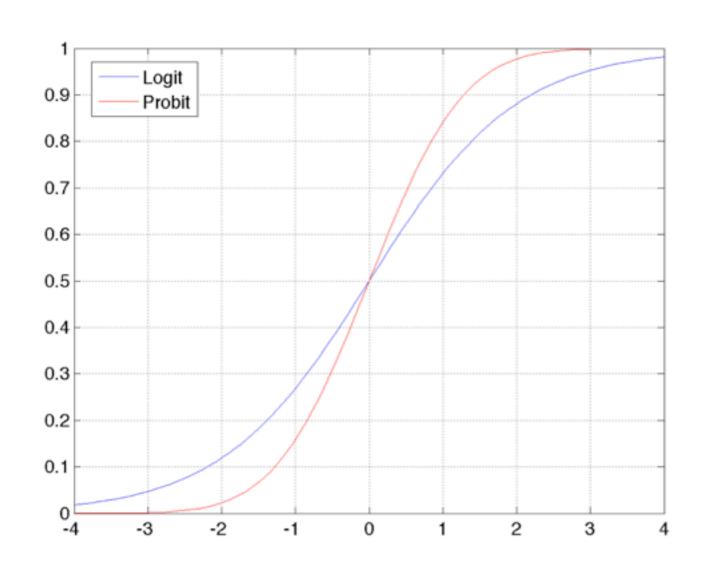
$$e_i = p(z_i = 1 | \boldsymbol{x}_i)$$

 Z_i : 第i対象者の割当変数の値

 $oldsymbol{x}_i$: 第i対象者の共変量の値

傾向スコアの推定

プロビット回帰やロジスティック回帰で推定する



$$\hat{e}_i = \int \frac{1}{\sqrt{2\pi}} \exp\{-\frac{z^2}{2}\} dz$$

$$\hat{e}_i = \frac{1}{1 + \exp\{-\hat{\boldsymbol{\alpha}}^t \boldsymbol{x}_i\}}$$

傾向スコアを用いた調整

・マッチング

2つの群で傾向スコアが等しい(近い)対象者をペアにしてその差の平均を因果効果とする

層別解析

傾向スコアの大小によっていくつかのサブクラスに分け、その各クラスで処置群と対照群の平均の計算と、全体としての効果の推定量を計算する

• 共分散分析

• 割当変数と傾向スコアを説明変数とした線形の回帰 分析を行う

傾向スコアを用いた調整の問題点

マッチング・層別解析

- 因果効果の推定値は計算出来るが、その標準語さが 計算出来ない
- 各周辺期待値の推定が出来ない
- マッチングの場合、対象者の数が多い群でデータの 多くが無駄になる
- マッチングによる推定値は「対象者数の少ない群の 共変量の分布」の上で期待値を取った時の因果効果

• 共分散分析

• 傾向スコアと目的変数が線形な関係にある必要があるが、傾向スコアが0~1である以上、その関係の仮定には無理がある

IPW推定量

傾向スコアの逆数による重み付け平均

$$\hat{E}(y_1) = \frac{\sum_{i=1}^{N} \frac{z_i y_i}{e_i}}{\sum_{i=1}^{N} \frac{z_i}{e_i}}$$

$$\hat{E}(y_0) = \frac{\sum_{i=1}^{N} \frac{(1-z_i)y_i}{1-e_i}}{\sum_{i=1}^{N} \frac{(1-z_i)y_i}{1-e_i}}$$

カーネルマッチング

カーネルを利用した重みで 対照群の全ての観測値を重み付ける

$$\hat{y}_{i0} = \frac{\sum_{j=1}^{N} (1 - z_j) K_{ij} y_{j0}}{\sum_{j=1}^{N} (1 - z_j) K_{ij}}$$

カーネルマッチング

カーネルを利用した重みで 対照群の全ての観測値を重み付ける

$$\hat{y}_{i0} = \frac{\sum_{\substack{j=1\\ \text{D-ALOBH}}}^{N} (1-z_j) K_{ij} y_{j0}}{\sum_{\substack{j=1\\ j=1}}^{N} (1-z_j) K_{ij}}$$

AGENDA

- 自己紹介
- 傾向スコア解析
 - 実験出来るデータ
 - ・実験出来ないデータ
 - 共変量調整
 - 傾向スコア推定
 - 傾向スコアを用いた調整
- Rによる実行
- 最後に

Rによる実行

Matching パッケージ

Match(Y=NULL, Tr, X, caliper=F,...)

Y:結果ベクトル

Tr:割当ベクトル

X:共変量または傾向スコア

caliper:キャリパーマッチングをやる場合にTRUE

- - -

Rによる実行

Matching パッケージ

lalondeデータセット

データセットの説明

Rでマッチング実行

マッチングを実行するコード

```
install.packages("Matching")
    library(Matching)
3
    ##
   ## Matching
    data(lalonde)
    Y78 <- lalonde$re78
10
    Tre <- lalonde$treat
11
12
    logi <- glm(treat~., data=lalonde[,-9],family=binomial)</pre>
13
    ## default
14
15
    summary(Match(Y=Y78, Tr=Tre,X=logi$fitted))
16
17
    ##
    summary(Match(Y=Y78, Tr=Tre,X=logi$fitted,M=2))
18
19
20
    ## caliper matching
21
    summary(Match(Y=Y78, Tr=Tre,X=logi$fitted,caliper=T))
```

Rでマッチング実行

通常のマッチングの 実行結果と解説

Rでマッチング実行

キャリパーマッチングの 実行結果と解説

RでIPW推定量

IPW推定量の実行コード

RでIPW推定量

IPW推定量の 実行結果と解説

Rでカーネルマッチング実行

マッチングを実行するコード

```
23
     ##
    ## kernel matching
24
25
    ##
26
    kmy <- lalonde$re74
27
     ivec1 <- lalonde$treat
28
    estp <- logi$fitted
29
    km <- cbind(kmy,estp, ivec1)</pre>
30
    km1 <- subset(km, ivec1==1)</pre>
31
    km2 <- subset(km, ivec1==0)</pre>
32
    km1x \leftarrow km1[,2]
33
34
    km1y \leftarrow km1[,1]
35
    km2x <- km2[,2]
     km2y \le km2[,1]
36
     bw1 \leftarrow 1.06*(nrow(km1))^{(-0.2)} * sd(km1x)
37
     bw2 \leftarrow 1.06*(nrow(km2))^{(-0.2)} * sd(km2x)
38
     esty1 <- ksmooth(x=km1x,y=km1y,kernel="normal",
39
40
                        bandwidth=bw1,x.points=km2x)
     esty0 <- ksmooth(x=km2x,y=km2y,kernel="normal",
41
                       bandwidth=bw2,x.points=km1x)
42
43
44
     head(esty1$y)
45
46
     head(esty0$y)
```

Rでカーネルマッチング実行

カーネルマッチングの 実行結果と解説

AGENDA

- 自己紹介
- ・傾向スコア解析
 - ・実験出来るデータ
 - ・実験出来ないデータ
 - 共変量調整
 - ・傾向スコア推定
 - 傾向スコアを用いた調整
- Rによる実行
- 最後に

次回以降の 発表者・LTを募集しています!

ご清聴ありがとうございました

AGENDA

- 自己紹介
- ・傾向スコア解析
 - ・実験出来るデータ
 - ・実験出来ないデータ
 - 共変量調整
 - ・傾向スコア推定
 - 傾向スコアを用いた調整
- Rによる実行
- 最後に

参考文献

- 調査観察データの統計科学
- Package 'Matching'

傾向スコア解析

実験出来ないデータの因果関係を解析する

